

Deteccção de artefatos de arritmia utilizando Máquinas de Vetores de Suporte e Coeficientes de Energia Wavelet

Proposta de TCC

Gabriel Lechenco Vargas Pereira

Cristiano Marcos Agulhari

2020

Universidade Tecnológica Federal do Paraná - UTFPR

1. Introdução
2. Fundamentação Teórica
3. Revisão de Literatura
4. Proposta
5. Considerações Finais

Introdução

Estatísticas de doenças cardiovasculares: [5]

- Foram responsáveis por um terço das mortes em 2016
- Três quartos dessas ocorreram em países de baixa e média renda
- A principal causa das mortes são diagnóstico feito tardiamente

O desenvolvimento de modelos computacionais com a capacidade de identificar artefatos de arritmia pode auxiliar em um diagnóstico mais rápido de doenças cardiovasculares.

Este trabalho consiste em encontrar novas estratégias para se diferenciar de forma automatizada trechos de eletrocardiograma em múltiplas classes, a fim de identificar artefatos de arritmia de naturezas diversas.

Dessa forma, serão utilizados:

- Identificar e recortar os trechos de sinal ECG relevantes
- Utilizar como vetor de características coeficientes de energia wavelet
- Treinar um modelo de Aprendizado de Máquina Supervisionado (SVM)

Fundamentação Teórica

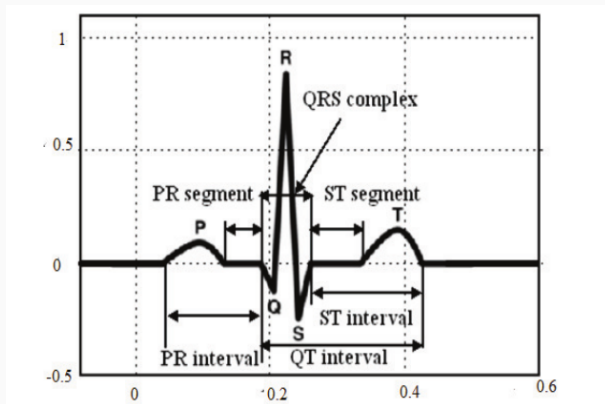


Figure 1: Ciclo PQRST [2]

A falta de ritmo cardíaco tem ampla influência sobre a saúde do paciente.

- Deficiência no transporte e fornecimento de oxigênio.
- Podendo acarretar complicações em todo o corpo.
- Algumas capazes de levar ao óbito em poucos minutos.

Exemplo Eletrocardiograma




Figure 2: Trecho batimentos ritmo normal

Exemplo Eletrocardiograma




Figure 3: Trecho batimentos com fibrilação atrial

Aprendizado de Máquina Supervisionado (SVM)

Máquinas de Vetores de Suporte (SVM)

Algoritmo de classificação binária que busca encontrar o hiperplano ótimo que seccione o hiperespaço onde os dados se encontram.

$$f(x) = \langle w, x \rangle + b = 0$$

Máquinas de Vetores de Suporte (SVM)

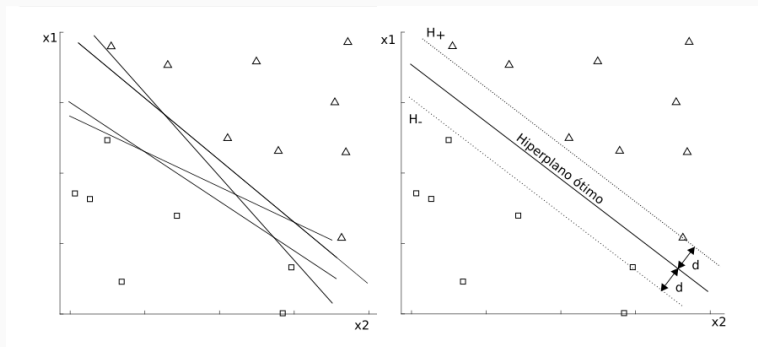


Figure 4: Separação de dois planos por um hiperplano ótimo

Máquinas de Vetores de Suporte (SVM)

Vantagens

- Otimização de natureza convexa
- Apresenta um unico mínimo global para problemas lineares
- Consegue bons resultados com poucos exemplos

Desvantagens

- A princípio resolve apenas problemas lineares
- Classificação binária

Teorema de Cover

Dado um problema de classificação de padrões complexo, ao lançá-lo em um espaço com muitas dimensões é mais provável que este seja linearmente separável do que em um espaço com poucas dimensões, desde que o espaço não seja densamente preenchido. [3]

A adição de diferentes kernels possibilita uma maior flexibilidade do algoritmo de SVM com uma pequena modificação no problema de otimização.

$$f(x) = \langle w, \Phi(x) \rangle + b = 0$$

Problema XOR




Figure 5: SVM utilizando o kernel gaussiano para o problema XOR

Técnicas pra classificação não binária

- *One Against All* (OAA)
- *One Against One* (OAO)
- *Directed Acyclic Graph SVM* (DAGSVM)
- *Binary Tree of SVM* (BTS)

Estração de Características (Wavelet)




Figure 6: Onda com energia infinita e wavelet com energia concentrada [1]

Características das funções Wavelet:

- Infinitas funções wavelet disponíveis
- Localização em tempo-frequência (Escala e Translação)
- Multirresolução

A Transformada de Wavelet Discreta prioriza naturalmente uma melhor precisão em identificar as baixas frequências que compõem o sinal e uma melhor localização no tempo das altas frequências que causam fenômenos e perturbações momentâneas. [4]

Filter Bank e Wavelet Packets




Figure 7: Árvores de Decomposição Wavelet

Revisão de Literatura

Trabalho	Técnica
Govindan, Deng e Power (1997)	Wavelet + Redes Neurais
Zhao e Zhang (2005)	Wavelet + SVM + Modelagem Autorregressiva
Mora e Amaya (2012)	Entropia de Shannon + Complexidade de Lempel-Ziv + SVM-OAO assimétrica
Rua et al. (2012)	Energia Wavelet + Redes Neurais
Azariadi et al. (2016)	Wavelet + SVM
Tuncer et al. (2019)	Wavelet + Localização de padrões locais hexadecimais + KNN

Trabalho	Nº de classes	Nº de Exemplos no treinamento	Acurácia
Govindan, Deng e Power (1997)	4	10	77% \pm 9%
Zhao e Zhang (2005)	6	7940	99,68%
Mora e Amaya (2012)	5	637	90,72%
Rua et al. (2012)	2	-	99.46%
Azariadi et al. (2016)	2	104581	97%
Tuncer et al. (2019)	17	-	95.0%

Proposta




Figure 8: Descrição do Método que será utilizado

Bases de dados

- MIT-BIH Arrhythmia Database (mitdb)
 - Trechos de arritmia
 - Trechos saudáveis
- MIT-BIH Normal Sinus Rhythm Database (nsrdb)
 - Trechos saudáveis

Localizar e seccionar trechos selecionados:

- Ler anotações e comentários presentes nas bases de dados
- Localizar o início e término de eventos arrítmicos
- Seccionar trechos a cada 8 segundos
- Realizar reamostragem para 128Hz

Cada trecho de sinal será decomposto até o quarto nível, no final a folha mais a esquerda será decomposta por mais dois níveis. Será utilizada a função *Daubechies* com suporte 3, por se adequar bem aos sinais cardíacos.

Estração de Características

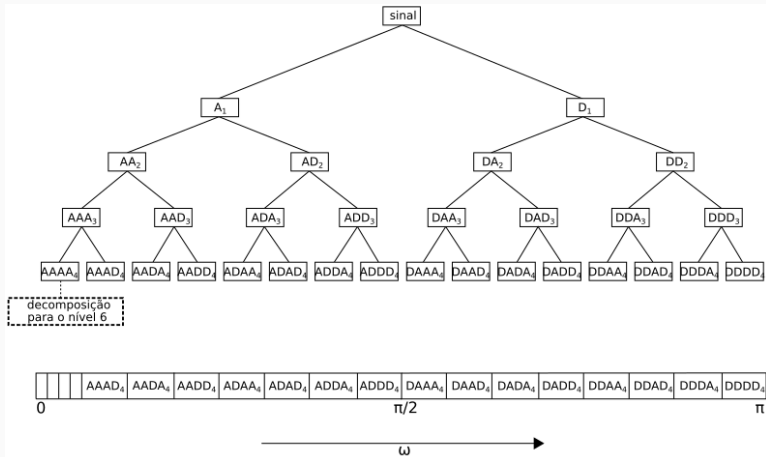


Figure 9: Decomposição Wavelet proposta

Máquinas de Vetores de Suporte (SVM)

- Aprendizado supervisionado
- Comparação entre técnicas de classificação multiclass

Sigla	Classe
N	Batimentos com ritmos normais
AFIB	Fibrilação Atrial
SBR	Bradicardia Sinusal
B	Bigeminia Ventricular

Data	Atividade
14/Agosto	Selecionar trechos relevantes dos sinais biológicos com base nas anotações do banco de dados
28/Agosto	Realizar o janelamento e padronização destes trechos
11/Setembro	Extrair Energias Wavelet
02/Outubro	Realizar Classificações
23/Outubro	Agrupar Resultados
20/Novembro	Descrever Resultados e Conclusões finais

Data	Atividade
14/Agosto	Selecionar trechos relevantes dos sinais biológicos com base nas anotações do banco de dados
28/Agosto	Realizar o janelamento e padronização destes trechos
11/Setembro	Extrair Energias Wavelet
02/Outubro	Realizar Classificações
23/Outubro	Agrupar Resultados
20/Novembro	Descrever Resultados e Conclusões finais

Considerações Finais

Perguntas?



C. Burrus, R. Gopinath, and H. Guo.

Introduction to Wavelets and Wavelet Transform—A Primer, volume 67.

01 1998.



S. Faziludeen and P. V. Sabiq.

ECG beat classification using wavelets and SVM.

In *2013 IEEE Conference on Information Communication Technologies*, pages 815–818, Apr. 2013.



S. Haykin.

Neural Networks and Learning Machines, 3/E.

Pearson Education India, 2010.



G. Strang and T. Nguyen.

Wavelets and filter banks.


SIAM, 1996.




WHO.

Cardiovascular diseases (CVDs), May 2017.

Directed Acyclic Graph SVM (DAGSVM)



Binary Tree of SVM (BTS)



Transformada de Wavelet Discreta

É possível reconstruir um sinal $f(t)$ partindo de uma única função wavelet mãe ψ e seus coeficientes de escala e translação $a_{j,k}$:

$$f(t) = \sum_{j,k} a_{j,k} \psi_{j,k}(t)$$