

Deteccção de artefatos de arritmia utilizando Máquinas de Vetores de Suporte e Coeficientes de Energia Wavelet

Proposta de TCC

Gabriel Lechenco Vargas Pereira

Cristiano Marcos Agulhari

2021

Universidade Tecnológica Federal do Paraná - UTFPR

Introdução

Estatísticas de doenças cardiovasculares: [3]

- Foram responsáveis por um terço das mortes em 2016
- Três quartos dessas ocorreram em países de baixa e média renda
- A principal causa das mortes são diagnóstico feito tardiamente

O desenvolvimento de modelos computacionais com a capacidade de identificar artefatos de arritmia pode auxiliar em um diagnóstico mais rápido de doenças cardiovasculares.

Este trabalho consiste em encontrar novas estratégias para se diferenciar de forma automatizada trechos de eletrocardiograma em múltiplas classes, a fim de identificar artefatos de arritmia de naturezas diversas.

- Identificar e recortar os trechos de sinal ECG relevantes
- Utilizar como vetor de características coeficientes de energia wavelet
- Treinar um modelo de Aprendizado de Máquina Supervisionado (SVM)

Fundamentação Teórica




Figure 1: Ciclo PQRST [2]

A falta de ritmo cardíaco tem ampla influência sobre a saúde do paciente.

- Deficiência no transporte e fornecimento de oxigênio.
- Podendo acarretar complicações em todo o corpo.
- Algumas capazes de levar ao óbito em poucos minutos.

Exemplo Eletrocardiograma




Figure 2: Trecho batimentos ritmo normal

Exemplo Eletrocardiograma




Figure 3: Trecho batimentos com fibrilação atrial

Exemplo Eletrocardiograma




Figure 4: Trecho batimentos com bigeminia ventricular

Exemplo Eletrocardiograma




Figure 5: Trecho batimentos com bradicardia sinusal

Aprendizado de Máquina Supervisionado (SVM)

Algoritmo de classificação binária que busca encontrar o hiperplano ótimo que seccione o hiperespaço onde os dados se encontram.

$$f(x) = \langle w, x \rangle + b = 0$$

Máquinas de Vetores de Suporte (SVM)

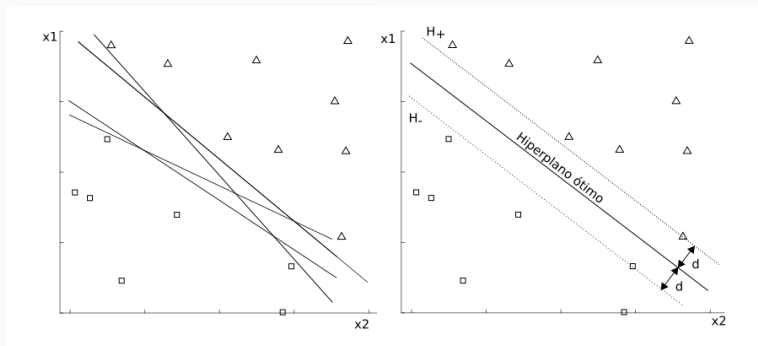


Figure 6: Separação de dois planos por um hiperplano ótimo

A adição de diferentes kernels possibilita uma maior flexibilidade do algoritmo de SVM com uma pequena modificação no problema de otimização.

$$f(x) = \langle w, \Phi(x) \rangle + b = 0$$

Problema XOR




Figure 7: SVM utilizando o kernel gaussiano para o problema XOR

Técnicas para classificação não binária

- *One Against All* (OAA)
- *One Against One* (OAO)
- *Directed Acyclic Graph SVM* (DAGSVM)
- *Binary Tree of SVM* (BTS)

Extração de Características (Wavelet)




Figure 8: Onda com energia infinita e wavelet com energia concentrada [1]

Características das funções Wavelet:

- Infinitas funções wavelet disponíveis
- Localização em tempo-frequência (Escala e Translação)
- Multirresolução

É possível reconstruir um sinal $f(t)$ partindo de uma única função wavelet mãe ψ e seus coeficientes de escala e translação $a_{j,k}$:

$$f(t) = \sum_{j,k} a_{j,k} \psi_{j,k}(t)$$

Filter Bank e Wavelet Packets




Figure 9: Árvores de Decomposição Wavelet

Metodologia

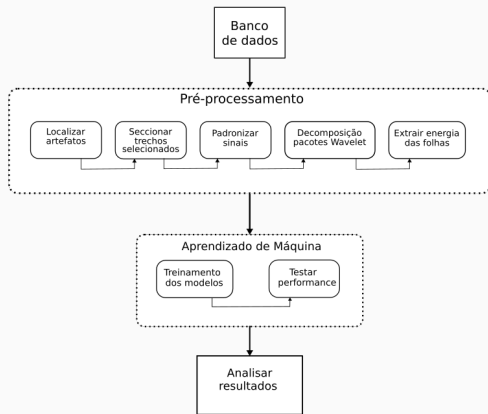


Figure 10: Descrição do Método que será utilizado

Bases de dados

- MIT-BIH Arrhythmia Database (mitdb)
 - Trechos de arritmia
 - Trechos saudáveis
- MIT-BIH Normal Sinus Rhythm Database (nsrdb)
 - Trechos saudáveis

Localizar e seccionar trechos selecionados:

- Ler anotações e comentários presentes nas bases de dados
- Localizar o início e término de eventos arrítmicos
- Seccionar trechos a cada 8 segundos
- Realizar reamostragem para 128Hz

Estração de Características

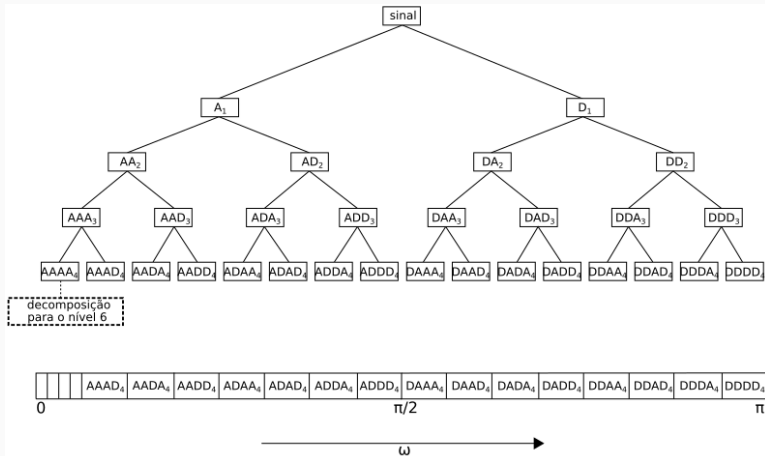


Figure 11: Decomposição Wavelet proposta

Máquinas de Vetores de Suporte (SVM)

- Aprendizado supervisionado
- Kernel Gaussiano
- *K-fold* e *Cross Validation*
- Comparação entre técnicas de classificação multiclases

Resultados

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

Matriz de Confusão




Figure 12: Matriz de Confusão para o modelo *One Against All*

		One Against One					
True Class	(AFIB	53	4	2	1	88.3%	11.7%
	(B	14	41	4	1	68.3%	31.7%
	(N	4	7	48	1	80.0%	20.0%
	(SBR		1	4	55	91.7%	8.3%
		74.6%	77.4%	82.8%	94.8%		
		25.4%	22.6%	17.2%	5.2%		
		(AFIB	(B	(N	(SBR		
		Predicted Class					

Figure 13: Matriz de Confusão para o modelo *One Against One*

Matriz de Confusão

		DAGSVM					
True Class	(AFIB	54	4	1	1	90.0%	10.0%
	(B	16	41	2	1	68.3%	31.7%
	(N	5	7	47	1	78.3%	21.7%
	(SBR	1	1	3	55	91.7%	8.3%
		71.1%	77.4%	88.7%	94.8%		
		28.9%	22.6%	11.3%	5.2%		
		(AFIB	(B	(N	(SBR		
		Predicted Class					

Figure 14: Matriz de Confusão para o modelo DAGSVM

Matriz de Confusão

		BTS					
True Class	(AFIB	54	4	1	1	90.0%	10.0%
	(B	12	45	2	1	75.0%	25.0%
	(N	3	7	48	2	80.0%	20.0%
	(SBR		1	3	56	93.3%	6.7%
		78.3%	78.9%	88.9%	93.3%		
		21.7%	21.1%	11.1%	6.7%		
		(AFIB	(B	(N	(SBR		
		Predicted Class					

Figure 15: Matriz de Confusão para o modelo *Binary Tree of SVM*

	AFIB	B	N	SBR	Average
One Against All	83.0%	80.4%	88.4%	87.9%	84.9%
One Against One	74.6%	77.4%	82.8%	94.8%	82.4%
Direct Acyclic Graph	71.1%	77.4%	88.7%	94.8%	83.0%
Binary Tree of SVM	78.3%	78.9%	88.9%	93.3%	84.9%

Table 1: Resumo da Precisão para cada um dos modelos testados.

	AFIB	B	N	SBR	Average
One Against All	73.3%	61.7%	63.3%	85.0%	70.8%
One Against One	88.3%	68.3%	80.0%	91.7%	82.1%
Direct Acyclic Graph	90.0%	68.3%	78.3%	91.7%	82.1%
Binary Tree of SVM	90.0%	75.0%	80.0%	93.3%	84.6%

Table 2: Resumo da *Recall* para cada um dos modelos testados.

Conclusão

Trabalhos Futuros

- Combinar os coeficientes de energia Wavelet com novas características
- Investigar classificações equivocadas

Considerações Finais

- A *Binary Tree of SVM* se destacou das demais
- A solução proposta alcançou resultados favoráveis

Perguntas?



C. Burrus, R. Gopinath, and H. Guo.

Introduction to Wavelets and Wavelet Transform—A Primer, volume 67.

01 1998.



S. Faziludeen and P. V. Sabiq.

ECG beat classification using wavelets and SVM.


In 2013 IEEE Conference on Information Communication Technologies, pages 815–818, Apr. 2013.



WHO.

Cardiovascular diseases (CVDs), May 2017.

Directed Acyclic Graph SVM (DAGSVM)



Binary Tree of SVM (BTS)

