

# **Detecção de artefatos de arritmia utilizando Máquinas de Vetores de Suporte e Coeficientes de Energia Wavelet**

Proposta de TCC

---

Gabriel Lechenco Vargas Pereira

Cristiano Marcos Agulhari

2020

Universidade Tecnológica Federal do Paraná - UTFPR

1. Introdução
2. Fundamentação Teórica
3. Revisão de Literatura
4. Proposta
5. Considerações Finais

# Introdução

---


## Doenças cardiovasculares

- Foram responsáveis por um terço das mortes em 2016
- Três quartos dessas ocorreram em países de baixa e média renda
- A principal causa das mortes são diagnóstico feito tardiamente

O desenvolvimento de modelos computacionais com a capacidade de identificar artefatos de arritmia podem auxiliar em um diagnóstico mais rápido de doenças cardiovasculares.

# Fundamentação Teórica

---



**Figure 1:** Ciclo PQRST [1]

A falta de ritmo cardíaco tem ampla influência sobre a saúde do paciente.

- Deficiência no transporte e fornecimento de oxigênio.
- Podendo acarretar complicações em todo o corpo.
- Algumas capazes de levar ao óbito em poucos minutos.




# Máquinas de Vetores de Suporte (SVM)

Algoritmo de classificação binária que busca encontrar o hiperplano ótimo que seccione o hiperespaço onde os dados se encontram.

$$f(x) = \langle w, x \rangle + b = 0$$

# Máquinas de Vetores de Suporte (SVM)



**Figure 2:** Separação de dois planos por um hiperplano ótimo

## Vantagens

- Otimização de natureza convexa
- Apresenta um unico mínimo global para problemas lineares
- Consegue bons resultados com poucos exemplos

# Máquinas de Vetores de Suporte (SVM)

## Vantagens

- Otimização de natureza convexa
- Apresenta um unico mínimo global para problemas lineares
- Consegue bons resultados com poucos exemplos

## Desvantagens

- A princípio resolve apenas problemas lineares
- Classificação binária


## Teorema de Cover

*Dado um problema de classificação de padrões complexo, ao lançá-lo em um espaço com muitas dimensões é mais provável que este seja linearmente separável do que em um espaço com poucas dimensões, desde que o espaço não seja densamente preenchido. [2]*

A adição de diferentes kernels possibilita uma maior flexibilidade do algoritmo de SVM com uma pequena modificação no problema de otimização.

$$f(x) = \langle w, \psi(x) \rangle + b = 0$$

# Problema XOR



**Figure 3:** SVM utilizando o kernel gaussiano para o problema XOR


Técnicas pra classificação não binária

- *One Against All* (OAA)
- *One Against One* (OAO)
- *Directed Acyclic Graph SVM* (DAGSVM)
- *Binary Tree of SVM* (BTS)




# SVM's e problemas não binários

## *Directed Acyclic Graph SVM (DAGSVM)*




# SVM's e problemas não binários

## *Binary Tree of SVM (BTS)*




A Transformada de Fourier é amplamente utilizada no processamento de sinais digitais, porém, ela pode não ser a mais adequada em alguns casos. Transformadas wavelet são mais apropriadas para a análise de fenômenos não estacionários ou variantes no tempo.



**Figure 4:** Onda de energia e infinita e wavelet de energia concentrada

Características das funções Wavelet:

- Infinitas funções wavelet disponíveis
- Localização em tempo-frequência (Escala e Translação)
- Multirresolução




**Figure 5:** Resolução no tempo-frequência STFT e Decomposição Wavelet

Ao tentar otimizar a propriedade de multirresolução, os *Filter Banks* combinam as decomposições multiníveis em uma árvore binária, construindo uma coleção de filtros passa-baixa e passa-alta.

Enquanto que as *Wavelet Packets* procuram uma análise mais completa dos filtros, a partir de uma decomposição binária.

# Filter Bank e Wavelet Packets



**Figure 6:** Árvores de Decomposição Wavelet



# Revisão de Literatura

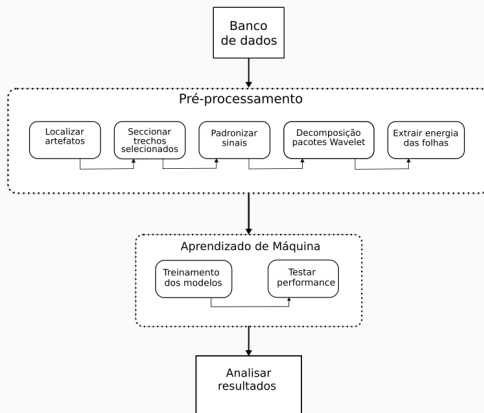
---

Trabalho	Técnica
Govindan, Deng e Power (1997)	Coeficientes Wavelet + Redes Neurais
Zhao e Zhang (2005)	Coeficientes Wavelet + SVM + Modelagem Autorregressiva
Mora e Amaya (2012)	Entropia de Shannon + Complexidade de Lempel-Ziv + SVM-OAO assimétrica
Rua et al. (2012)	Energia Wavelet + Redes Neurais
Azariadi et al. (2016)	Coeficientes Wavelet + SVM
Tuncer et al. (2019)	Decomposição Wavelet + Localização de padrões locais hexadecimais + KNN

Trabalho	Nº de classes	Nº de Exemplos no treinamento	Acurácia
Govindan, Deng e Power (1997)	4	10	77% $\pm$ 9%
Zhao e Zhang (2005)	6	7940	99,68%
Mora e Amaya (2012)	5	637	90,72%
Rua et al. (2012)	2	-	99.46%
Azariadi et al. (2016)	2	104581	97%
Tuncer et al. (2019)	17	-	95.0%

# Proposta

---



**Figure 7:** Descrição do Método que será utilizado

## Bases de dados

- MIT-BIH Arrhythmia Database (mitdb)
- MIT-BIH Normal SinusRhythm Database (nsrdb)

Localizar e seccionar trechos selecionados:

- Ler anotações e comentários presentes nas bases de dados
- Localizar o início e término de eventos arrítmicos
- Seccionar trechos a cada 8 segundos
- Padronizar taxa de amostragem para  $128\text{Hz}$
- Fazer o mesmo para os dados saudáveis

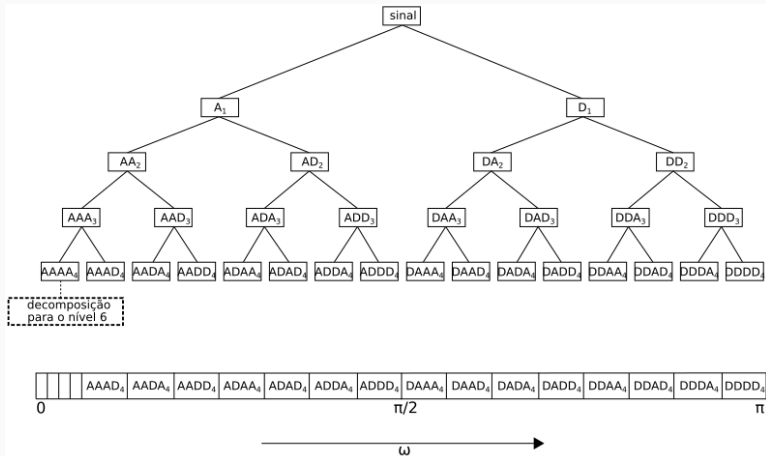
Localizar e seccionar trechos selecionados:

- Ler anotações e comentários presentes nas bases de dados
- Localizar o início e término de eventos arrítmicos
- Seccionar trechos a cada 8 segundos
- Padronizar taxa de amostragem para 128Hz
- Fazer o mesmo para os dados saudáveis



Cada trecho de sinal será decomposto até o quarto nível, no final a folha mais a esquerda será decomposta por mais dois níveis. Será utilizada a função *Daubechies* com suporte 3, por se adequar bem aos sinais cardíacos.

# Extração de características



**Figure 7:** Decomposição Wavelet proposta

## Máquinas de Vetores de Suporte (SVM)

- Aprendizado supervisionado
- Classificação entre 4 classes
- Comparação entre técnicas de classificação multiclass

Classificação entre 4 classes

Sigla	Classe
N	Batimentos com ritmos normais
AFIB	Fibrilação Arterial
SBR	Bradicardia Sinusal
ASV	Arritmia Supraventricular

Data	Atividade
14/Agosto	Selecionar trechos relevantes dos sinais biológicos com base nas anotações do banco de dados
28/Agosto	Realizar o janelamento e padronização destes trechos
11/Setembro	Extrair Energias Wavelet
02/Outubro	Realizar Classificações
23/Outubro	Agrupar Resultados
20/Novembro	Descrever Resultados e Conclusões finais

Data	Atividade
14/Agosto	<del>Selecionar trechos relevantes dos sinais biológicos com base nas anotações do banco de dados</del>
28/Agosto	<del>Realizar o janelamento e padronização destes trechos</del>
11/Setembro	Extrair Energias Wavelet
02/Outubro	Realizar Classificações
23/Outubro	Agrupar Resultados
20/Novembro	Descrever Resultados e Conclusões finais

## Considerações Finais

---



S. Faziludeen and P. V. Sabiq.

**ECG beat classification using wavelets and SVM.**

In *2013 IEEE Conference on Information Communication Technologies*, pages 815–818, Apr. 2013.



S. Haykin.

**Neural Networks and Learning Machines, 3/E.**

Pearson Education India, 2010.