

Detecção de artefatos de arritmia utilizando Máquinas de Vetores de Suporte e Coeficientes de Energia Wavelet

Proposta de TCC

Gabriel Lechenco Vargas Pereira

Cristiano Marcos Agulhari

2020

Universidade Tecnológica Federal do Paraná - UTFPR

1. Introdução
2. Fundamentação Teórica
3. Revisão de Literatura
4. Proposta
5. Considerações Finais

Introdução

Doenças cardiovasculares

- Foram responsáveis por um terço das mortes em 2016
- Três quartos dessas ocorreram em países de baixa e média renda
- A principal causa das mortes são diagnóstico feito tardiamente

O desenvolvimento de modelos computacionais com a capacidade de identificar artefatos de arritmia podem auxiliar em um diagnóstico mais rápido de doenças cardiovasculares.

Fundamentação Teórica




Figure 1: Ciclo PQRST [1]

A falta de ritmo cardíaco tem ampla influência sobre a saúde do paciente.

- Deficiência no transporte e fornecimento de oxigênio.
- Podendo acarretar complicações em todo o corpo.
- Algumas capazes de levar ao óbito em poucos minutos.

Exemplo Eletrocardiograma




Figure 2: Trecho batimentos ritmo normal

Exemplo Eletrocardiograma




Figure 2: Trecho batimentos com fibrilação atrial

Máquinas de Vetores de Suporte (SVM)

Algoritmo de classificação binária que busca encontrar o hiperplano ótimo que seccione o hiperespaço onde os dados se encontram.

$$f(x) = \langle w, x \rangle + b = 0$$

Máquinas de Vetores de Suporte (SVM)




Figure 3: Separação de dois planos por um hiperplano ótimo

Vantagens

- Otimização de natureza convexa
- Apresenta um unico mínimo global para problemas lineares
- Consegue bons resultados com poucos exemplos

Máquinas de Vetores de Suporte (SVM)

Vantagens

- Otimização de natureza convexa
- Apresenta um unico mínimo global para problemas lineares
- Consegue bons resultados com poucos exemplos

Desvantagens

- A princípio resolve apenas problemas lineares
- Classificação binária

Teorema de Cover

Dado um problema de classificação de padrões complexo, ao lançá-lo em um espaço com muitas dimensões é mais provável que este seja linearmente separável do que em um espaço com poucas dimensões, desde que o espaço não seja densamente preenchido. [2]

A adição de diferentes kernels possibilita uma maior flexibilidade do algoritmo de SVM com uma pequena modificação no problema de otimização.

$$f(x) = \langle w, \psi(x) \rangle + b = 0$$

Problema XOR





Figure 4: SVM utilizando o kernel gaussiano para o problema XOR

Técnicas pra classificação não binária

- *One Against All* (OAA)
- *One Against One* (OAO)
- *Directed Acyclic Graph SVM* (DAGSVM)
- *Binary Tree of SVM* (BTS)


SVM's e problemas não binários

Directed Acyclic Graph SVM (DAGSVM)



SVM's e problemas não binários

Binary Tree of SVM (BTS)



A Transformada de Fourier é amplamente utilizada no processamento de sinais digitais, porém, ela pode não ser a mais adequada em alguns casos. Transformadas wavelet são mais apropriadas para a análise de fenômenos não estacionários ou variantes no tempo.




Figure 5: Onda de energia e infinita e wavelet de energia concentrada

Características das funções Wavelet:

- Infinitas funções wavelet disponíveis
- Localização em tempo-frequência (Escala e Translação)
- Multirresolução

Ao tentar otimizar a propriedade de multirresolução, os *Filter Banks* combinam as decomposições multiníveis em uma árvore binária, construindo uma coleção de filtros passa-baixa e passa-alta.

Enquanto que as *Wavelet Packets* procuram uma análise mais completa dos filtros, a partir de uma decomposição binária.

Filter Bank e Wavelet Packets

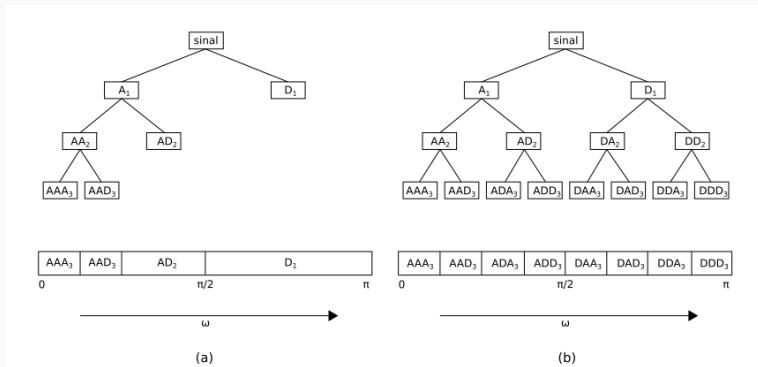


Figure 6: Árvores de Decomposição Wavelet

Revisão de Literatura

Trabalho	Técnica
Govindan, Deng e Power (1997)	Wavelet + Redes Neurais
Zhao e Zhang (2005)	Wavelet + SVM + Modelagem Autorregressiva
Mora e Amaya (2012)	Entropia de Shannon + Complexidade de Lempel-Ziv + SVM-OAO assimétrica
Rua et al. (2012)	Energia Wavelet + Redes Neurais
Azariadi et al. (2016)	Wavelet + SVM
Tuncer et al. (2019)	Wavelet + Localização de padrões locais hexadecimais + KNN

Trabalho	Nº de classes	Nº de Exemplos no treinamento	Acurácia
Govindan, Deng e Power (1997)	4	10	77% \pm 9%
Zhao e Zhang (2005)	6	7940	99,68%
Mora e Amaya (2012)	5	637	90,72%
Rua et al. (2012)	2	-	99.46%
Azariadi et al. (2016)	2	104581	97%
Tuncer et al. (2019)	17	-	95.0%

Proposta




Figure 7: Descrição do Método que será utilizado

Bases de dados

- MIT-BIH Arrhythmia Database (mitdb)
- MIT-BIH Normal Sinus Rhythm Database (nsrdb)

Bases de dados

- MIT-BIH Arrhythmia Database (mitdb)
 - Trechos de arritmia
 - Trechos saudáveis
- MIT-BIH Normal Sinus Rhythm Database (nsrdb)
 - Trechos saudáveis

Localizar e seccionar trechos selecionados:

- Ler anotações e comentários presentes nas bases de dados
- Localizar o início e término de eventos arrítmicos
- Seccionar trechos a cada 8 segundos
- Padronizar taxa de amostragem para 128Hz
- Fazer o mesmo para os dados saudáveis

Localizar e seccionar trechos selecionados:

- Ler anotações e comentários presentes nas bases de dados
- Localizar o início e término de eventos arrítmicos
- Seccionar trechos a cada 8 segundos
- Padronizar taxa de amostragem para 128Hz
- Fazer o mesmo para os dados saudáveis

Cada trecho de sinal será decomposto até o quarto nível, no final a folha mais a esquerda será decomposta por mais dois níveis. Será utilizada a função *Daubechies* com suporte 3, por se adequar bem aos sinais cardíacos.

Extração de características




Figure 8: Decomposição Wavelet proposta

Máquinas de Vetores de Suporte (SVM)

- Aprendizado supervisionado
- Classificação entre 4 classes
- Comparação entre técnicas de classificação multiclass

Classificação entre 4 classes

Sigla	Classe
N	Batimentos com ritmos normais
AFIB	Fibrilação Arterial
SBR	Bradicardia Sinusal
B	Bigeminia ventricular

Data	Atividade
14/Agosto	Selecionar trechos relevantes dos sinais biológicos com base nas anotações do banco de dados
28/Agosto	Realizar o janelamento e padronização destes trechos
11/Setembro	Extrair Energias Wavelet
02/Outubro	Realizar Classificações
23/Outubro	Agrupar Resultados
20/Novembro	Descrever Resultados e Conclusões finais

Data	Atividade
14/Agosto	Selecionar trechos relevantes dos sinais biológicos com base nas anotações do banco de dados
28/Agosto	Realizar o janelamento e padronização destes trechos
11/Setembro	Extrair Energias Wavelet
02/Outubro	Realizar Classificações
23/Outubro	Agrupar Resultados
20/Novembro	Descrever Resultados e Conclusões finais

Considerações Finais



S. Faziludeen and P. V. Sabiq.

ECG beat classification using wavelets and SVM.

In *2013 IEEE Conference on Information Communication Technologies*, pages 815–818, Apr. 2013.



S. Haykin.

Neural Networks and Learning Machines, 3/E.

Pearson Education India, 2010.